



دانشگاه آزاد اسلامی واحد تهران جنوب

گزارش سمینار درس بینایی ماشین

کارشناسی ارشد رشته مهندسی پزشکی گرایش بیوالکتریک

عنوان مقاله

Weakly Supervised Deep Learning for COVID-19 Infection Detection and Classification From CT Images

نگارنده:

امیرپویا گمرکچی

بهار 1403

چکیده

چکیده شیوع یک بیماری کروناویروس جدید (یعنی کووید-۱۹) از اواخر دسامبر ۲۰۱۹ در ووهان چین ثبت شده است که متعاقباً در سراسر جهان همه گیر شد. اگرچه کووید-۱۹ یک بیماری حاد درمان شده است، اما با خطر مرگ و میر ۴,۰۳ درصد در چین و بالاترین میزان ۱۳,۰۴ درصد در الجزایر و ۱۲,۶۷ درصد در ایتالیا (تا ۸ آوریل ۲۰۲۰) می تواند کشنده باشد. شروع یک بیماری جدی ممکن است در نتیجه آسیب قابل توجه آلوئول و نارسایی تنفسی پیشرونده منجر به مرگ شود. اگرچه تست های آزمایشگاهی، به عنوان مثال، استفاده از واکنش زنجیره ای پلیمرز رونویسی معکوس (RT-PCR)، استاندارد طلایی برای تشخیص بالینی است، آزمایش ها ممکن است منفی کاذب ایجاد کنند. علاوه بر این، در شرایط همه گیر، کمبود منابع آزمایش RT-PCR نیز ممکن است تصمیم بالینی و درمان زیر را به تاخیر بیندازد. در چنین شرایطی، تصویربرداری CT قفسه سینه به ابزاری ارزشمند برای تشخیص و پیش آگهی بیماران-COVID-۱۹ تبدیل شده است. در این مطالعه، ما یک استراتژی یادگیری عمیق با نظارت ضعیف برای شناسایی و طبقه بندی عفونت-COVID-۱۹ از تصاویر CT پیشنهاد می کنیم. روش پیشنهادی می تواند الزامات برچسب گذاری دستی تصاویر CT را به حداقل برساند، اما همچنان قادر به تشخیص دقیق عفونت و تشخیص-COVID-۱۹ از موارد غیر-COVID-۱۹ است. بر اساس نتایج امیدوارکننده به دست آمده از نظر کمی و کیفی، می توانیم به کارگیری گسترده تکنیک توسعه یافته خود را در مطالعات بالینی در مقیاس بزرگ متصور شویم.

کلید واژه: اصطلاحات شاخص کووید-۱۹، یادگیری عمیق، نظارت ضعیف، تصاویر سی تی، طبقه بندی، شبکه عصبی کانولوشنال.

فهرست مطالب

فصل 1. بیان مساله و ضرورت انجام پژوهش 2

1-1 پیشگفتار 2

2-1 بیان مساله 3

3-1 اهمیت و ضرورت انجام پژوهش 3

فصل 2. روش پیشنهادی 4

2-1 مواد و روش ها 4

2-2-1-2 جزئیات پیاده سازی 9

2-2-2-1-2 افزایش داده ها 10

فصل 3. نتایج و ارزیابی مدل‌های پیشنهادی 11

1-3 مقدمه 11

A. قطعه بندی ریه 11

1-3-1 رده بندی خاص 12

2-3-1 عملکرد طبقه بندی 13

3-1-2-1 بحث 16

3-2-2-1 نتیجه گیری 17

مراجع 19

فصل 1. بیان مساله و ضرورت انجام پژوهش

1-1 پیشگفتار

بیماری کروناویروس ۲۰۱۹ (COVID-۱۹) از دسامبر ۲۰۱۹ در سراسر جهان شیوع یافته است. این بیماری بسیار مسری است و موارد شدید می تواند منجر به ناراحتی حاد تنفسی یا نارسایی چند عضوی شود. در ۱۱ مارس ۲۰۲۰، WHO ارزیابی کرد که COVID-۱۹ می تواند به عنوان یک بیماری همه گیر شناخته شود. تا ۸ آوریل ۲۰۲۰، در مجموع، ۱،۳۹۱،۸۹۰ مورد کووید-۱۹ ثبت شده است و با افزایش سریع موارد در اروپا و آمریکای شمالی، تعداد قربانیان به ۸۱،۴۷۸ رسیده است. این بیماری را می توان با استفاده از تست واکنش زنجیره ای پلیمرز رونویسی معکوس (RT-PCR) تایید کرد. در حالی که استاندارد طلایی برای تشخیص است، تایید بیماران COVID-19 با استفاده از RT-PCR زمان بر است و هم نرخ منفی کاذب بالا و هم حساسیت کم ممکن است مانعی برای شناسایی و درمان زودهنگام بیماران احتمالی به عنوان یک غیر تهاجمی باشد. تکنیک تصویربرداری، توموگرافی کامپیوتری (CT) می تواند این ویژگی ها را تشخیص دهد، به عنوان مثال، سایه های تکه ای دوطرفه یا کدورت شیشه زمین (GGO)، که در ریه آلوده به کووید-۱۹ آشکار می شود. از این رو CT ممکن است به عنوان یک ابزار مهم برای غربالگری و تشخیص زودهنگام بیماران COVID-۱۹ عمل کند. علیرغم مزایای آن، CT ممکن است برخی از ویژگی های تصویری مشترک بین COVID-19 و سایر انواع ذات الریه را به اشتراک بگذارد که تشخیص خودکار را دشوار می کند. اخیراً، فناوری هوش مصنوعی مبتنی بر یادگیری عمیق (AI) موفقیت فوق العاده ای را در زمینه تجزیه و تحلیل داده های پزشکی به دلیل ظرفیت استخراج ویژگی های غنی از مجموعه داده های بالینی چندوجهی نشان داده است. پیش از این، یادگیری عمیق برای تشخیص و تمایز پنومونی باکتریایی و ویروسی از داده های تصویربرداری قفسه سینه توسعه داده شد. علاوه بر این، تلاش هایی برای شناسایی ویژگی های مختلف تصویربرداری CT قفسه سینه در همه گیری COVID-۱۹ فعلی، روش های مبتنی بر یادگیری عمیق به طور موثر برای تجزیه و تحلیل داده های CT قفسه سینه و طبقه بندی توسعه داده شده است. علاوه بر این، الگوریتم های یادگیری عمیق برای نظارت، غربالگری و پیش بینی اقامت در بیمارستان COVID-19 پیشنهاد شده اند.

2-1 بیان مساله

یک کروناویروس جدید COVID-19، متعلق به خانواده‌ای از سندرم حاد تنفسی ویروس کرونا SARS-CoV-2 در شهر ووهان، هوبی، چین، در نوامبر ۲۰۱۹ شناسایی شد. این بیماری تا ۱۳ مارس ۲۰۲۳ بیش از ۶۸۱,۵۲۹,۶۶۵ میلیون نفر را مبتلا کرده بود.

3-1 اهمیت و ضرورت انجام پژوهش

از این رو، تشخیص و تشخیص زودهنگام COVID-19 ضروری است. برای این منظور، رادیولوژیست ها از تصاویر پزشکی مانند اشعه ایکس و تصاویر توموگرافی کامپیوتری (CT) برای تشخیص COVID-19 استفاده می کنند. کمک به رادیولوژیست ها در انجام تشخیص های خودکار با استفاده از روش های سنتی پردازش تصویر برای محققان بسیار دشوار است

فصل 2. روش پیشنهادی

1-2 مواد و روش ها

A بیماران و داده ها این مطالعه گذشته نگر توسط هیئت بازبینی سازمانی بیمارستان های شرکت کننده مطابق با رویه های اخلاقی محلی تایید شد. رضایت بیشتر با تأیید لغو شد. این مطالعه شامل ۱۵۰ آزمایش CT حجمی قفسه سینه از بیماران COVID-19، CAP و NP بود. در مجموع، ۴۵۰ اسکن بیمار از دو بیمارستان شرکت کننده بین سپتامبر ۲۰۱۶ و مارس ۲۰۲۰ برای تجزیه و تحلیل بیشتر گنجانده شد. همه بیماران COVID-19 با آزمایش RT-PCR که از دسامبر ۲۰۱۹ تا مارس ۲۰۲۰ اسکن شده بودند، مثبت بودند. طبق برنامه تشخیص و درمان COVID-19 (نسخه آزمایشی ششم) صادر شده توسط کمیسیون بهداشت ملی در چین، طبقه بندی بالینی بیماران COVID-19 را می توان به عنوان خفیف، متوسط، شدید و بحرانی طبقه بندی کرد. همه بیماران COVID-19 ما در مرحله شدید یا بحرانی بودند و تمام سی تی اسکن ها در عرض ۳ روز پس از بستری در بیمارستان انجام شده بود. بیماران CAP و سایر NP بدون بیماری ریوی، ندول های ریوی، التهاب مزمن، بیماری انسدادی مزمن ریه) به طور تصادفی از بیمارستان های شرکت کننده بین سپتامبر ۲۰۱۶ تا ژانویه ۲۰۲۰ انتخاب شدند. معیارهای ورود بیماران CAP مطابق با دستورالعمل های مدیریت است. پنومونی اکتسابی از جامعه در بزرگسالان منتشر شده توسط انجمن بیماری های عفونی آمریکا/انجمن قفسه سینه آمریکا تشخیص CAP بر وجود ویژگی های بالینی شناسایی شده (مانند سرفه، تب، ایجاد خلط و درد قفسه سینه پلوریتیک) متمرکز است و با معاینه ریوی، معمولاً با اشعه ایکس قفسه سینه و در مورد ما با استفاده از سی تی همراه است. در معاینه منظم بیماران مشکوک به CAP، رادیوگرافی قفسه سینه برای تعیین تشخیص و تشخیص بهتر CAP از سایر علل خاص سرفه و تب، مانند برونشیت حاد، مورد نیاز است. اگرچه تظاهرات مختلف CT ممکن است به دلیل پاتوژن های مختلف مشاهده شود، همه بیماران CAP ما کشت باکتریایی را تایید کردند.

موارد یا موارد منفی، به عنوان مثال، با مایکروپلازما و پنومونی ویروسی. فرض ما این است که روش یادگیری عمیق با نظارت ضعیف پیشنهادی می‌تواند تفاوت‌های ظریف را در تصاویر CT به دست آمده برای بیماران CAP و COVID-19 حس کند. بیماران NP بدون بیماری ریوی یا بیماری ریوی، به عنوان مثال، ندول‌های ریوی، التهاب مزمن، بیماری انسدادی مزمن ریه و موارد دیگر تشخیص داده شدند. قابل ذکر است که معیار CT طبیعی در زمینه این است که در معاینات CT هیچ ضایعه آشکاری در هر دو ریه نشان داده نشده باشد. آنالیز واریانس یک طرفه (Analysis Of Variance) بر روی توزیع جنسیتی و سنی در سه گروه بیمار انجام شد و مقادیر p به دست آمده نشان می‌دهد که تفاوت معنی داری بین سه گروه وجود ندارد. از نظر توزیع جنسیتی و سنی ($p < 0.05$). بیماران COVID-19 از دو بیمارستان در چین، شامل ۱۳۸ بیمار از بیمارستان جامعه صلیب سرخ ووهان (WHRCH) و ۱۲ بیمار از بیمارستان دوم شنژن (SZSH) بستری شدند. هر دو بیماران CAP و NP از SZSH انتخاب شدند. بیماران COVID-19 از سیستم‌های سی‌تی سی‌تی Siemens SOMATOM go.Now ۱۶ (WHRCH) یا GE Revolution ۲۵۶ (SZSH) دریافت شدند. برای سیستم Siemens SOMATOM go.Now ۱۶ CT، پارامترهای اسکن به شرح زیر بود: ولتاژ لوله = ۱۳۰ کیلو ولت، مدولاسیون جریان لوله اتوماتیک = ۵۰ میلی آمپر، گام = ۱.۵ میلی متر، ماتریس = 512×512 ، ضخامت برش = ۰.۷ میلی متر، میدان = ۰.۷ میلی متر نما = 350×350 میلی متر، و ضخامت برش بازسازی شده = ۱ میلی متر. برای سیستم GE Revolution ۲۵۶ CT، پارامترهای اسکن به صورت ولتاژ لوله = ۱۲۰ کیلو ولت بر ثانیه، مدولاسیون جریان اتوماتیک لوله = ۱۵۰ میلی آمپر، گام = 1.375 میلی متر، ماتریس = 512×512 ، ضخامت برش = 0.625 میلی متر، میدان = ۰ تنظیم شد. میلی متر $400 \times$ میلی متر، و ضخامت برش بازسازی شده = ۲ میلی متر. تمام بیماران CAP و NP با استفاده از سیستم Siemens SOMATOM Emotion CT با پارامترهای تصویربرداری اصلی ولتاژ لوله = ۱۱۰ کیلو ولت بر ثانیه، مدولاسیون جریان اتوماتیک لوله = ۷۰ میلی آمپر، گام = 1.2 میلی متر، ماتریس = 512×512 ، ضخامت برش = 512.2 میلی متر اسکن شدند. ، میدان دید = 260×260 میلی متر، و ضخامت برش بازسازی شده = 1.5 میلی متر.

و 5Conv به لایه‌های طبقه‌بندی با نظارت ضعیف وارد کردیم، که در آن کانولوشن 1×1 برای ترسیم نقشه‌های ویژگی به نقشه‌های امتیاز کلاس اعمال شد. (یعنی نقشه‌های فعال سازی کلاس). سپس ما یک تجمیع فضایی را با یک عملیات جمع‌بندی حداکثر جهانی (GMP) برای بدست آوردن امتیازات طبقه‌بندی اعمال کردیم. بردارهای نمرات در سطوح 3Conv ، 4Conv و 5Conv با مجموع جمع شدند تا پیش‌بینی نهایی با تابع Softmax انجام شود

پس از تعیین نقشه‌های امتیاز کلاس و دسته تصویر در یک گذر رو به جلو از شبکه، الگوهای متمایز مربوط به آن دسته می‌توانند سپس در تصویر بومی سازی شوند. می‌توان با ارتباط مستقیم هر یک از نورون‌های موجود در نقشه‌های امتیاز کلاس به میدان پذیرای آن در تصویر اصلی، محلی سازی درشت را به دست آورد. با این حال، به دست آوردن نقشه‌های پیکسلی حاوی اطلاعاتی در مورد مکان ساختارهای هدف خاص کلاس در وضوح تصاویر ورودی اصلی نیز امکان پذیر است. این را می‌توان با محاسبه میزان تأثیر هر پیکسل بر فعال شدن نورون‌ها در نقشه امتیاز هدف به دست آورد. چنین نقشه‌هایی را می‌توان برای به دست آوردن محلی سازی بسیار دقیق‌تر، مانند مثال‌های نشان داده شده در شکل ۲، استفاده کرد. در ادامه، نشان خواهیم داد که چگونه می‌توان نقشه‌های برجستگی طبقه‌بندی خاص را از طریق گرادیان‌های یکپارچه به دست آورد. علاوه بر این، ما همچنین نحوه پس پردازش نقشه‌های برجسته را نشان خواهیم داد که از آن می‌توانیم جعبه های محدود کننده اطراف ضایعات شناسایی شده را استخراج کنیم.

گرادیان را می‌توان با انتشار مجدد امتیاز پیش بینی نهایی در هر لایه از شبکه تخمین زد. بسیاری از روش‌های پیشرفته‌ای برای انتشار پشت سر وجود دارد، از جمله انتشار به عقب هدایت شده، DeepLift و Layer-wise Relevance Propagation (LRP). با این حال، روش Guided-Backpropagation ممکن است حساسیت گرادیان را بشکند، زیرا تنها در صورتی که ReLU در ورودی روشن باشد، از طریق گره ReLU به عقب انتشار می‌یابد. به طور خاص، فقدان حساسیت باعث می‌شود که گرادیان‌ها بر روی ویژگی‌های نامربوط تمرکز کنند و منجر به محلی سازی نامطلوب برجستگی شود. روش‌های DeepLift و LRP با محاسبه گرادیان‌های گسسته به جای گرادیان‌های آنی در ورودی، مسئله حساسیت را حل می‌کنند. با این حال، آنها نمی‌توانند عدم تغییر پیاده سازی را برآورده کنند زیرا قانون زنجیره برقرار نیست.

۲- استخراج جعبه محدود

در مرحله بعد، نقشه برجستگی مشترک را که می توان از آن یک جعبه مرزی استخراج کرد، پس پردازش کردیم. ابتدا قدر مطلق نقشه برجسته مشترک را گرفتیم و آن را با یک هسته گاوسی 5×5 تار کردیم. سپس، با استفاده از روش آستانه‌ای Isodata، نقشه برجستگی تار را آستانه‌گذاری کردیم که به طور مکرر آستانه‌ای را تعیین کرد که تصویر را به پیش‌زمینه و پس‌زمینه تقسیم می‌کند، جایی که آستانه بین میانگین شدت پیکسل‌های پیش‌زمینه و پس‌زمینه نمونه‌برداری شده در میانه راه بود. با انجام این کار، یک ماسک دوتایی به دست آوردیم که روی آن عملیات مورفولوژیکی (اتساع و به دنبال آن فرسایش) برای بستن سوراخ‌های کوچک در پیش‌زمینه اعمال کردیم. در نهایت، اجزای متصل را با نواحی بالاتر از یک آستانه مشخص برداشتیم و حداقل جعبه‌های مرز مستطیلی را در اطراف آنها قرار دادیم. یک مثال در شکل ۲ (f) نشان داده شده است.

2-2-1-2 جزئیات پیاده سازی

۱- راه‌اندازی آزمایش‌ها ما مدل پیشنهادی را برای یک طبقه‌بندی سه‌طرفه (یعنی $K = 3$ برای NP، CAP و COVID-19) و سه کار طبقه‌بندی باینری ($K = 2$)، یعنی NP در مقابل COVID-19 آموزش دادیم. به ترتیب NP در مقابل CAP و CAP در مقابل COVID-19. در تنظیمات طبقه‌بندی سه‌طرفه، ابتدا طبقه‌بندی‌کننده‌های فردی را در بلوک‌های پیچشی مختلف آموزش دادیم. در آزمایش خود، به ترتیب Conv 3، Conv 4 و Conv 5 را انتخاب کردیم. سپس، ما یک طبقه‌بندی مشترک را بر روی نمرات پیش‌بینی انبوه (همانطور که در بخش «آموزش چند مقیاسی» توضیح داده شد، آموزش دادیم. همه طبقه‌بندی‌کننده‌ها با باخت در معادله آموزش دیده بودند. ۱. در نهایت، ما یک اعتبارسنجی متقاطع ۵ برابری روی تمام وظایف انجام دادیم که در هر دسته، مجموعه داده‌ها را به آموزش، اعتبارسنجی و مجموعه آزمایشی تقسیم کردیم. این می‌تواند تضمین کند که هیچ نمونه (تصاویری) که از اعتبارسنجی و آزمایش بیماران برای آموزش استفاده نشده است. در هر فولد، ۲۰ درصد از تمام نمونه‌ها را برای اعتبارسنجی و آزمایش نگه داشتیم و بقیه برای آموزش استفاده شد.

۲- تنظیمات آموزشی

ما مدل پیشنهادی را (همانطور که در شکل ۱ نشان داده شده است) با استفاده از Tensorflow ۱,۱۴,۰ پیاده سازی کردیم. همه مدل‌ها از ابتدا روی چهار پردازنده گرافیکی Nvidia GeForce GTX ۱۰۸۰ Ti با بهینه‌ساز Adam آموزش داده شدند (نرخ یادگیری: 10^{-4} ، $\beta_1 = 0.5$ ، $\beta_2 = 0.9$ و $\epsilon = 10^{-8}$). ما γ را روی ۱ در مدولاتور کانونی f قرار دادیم و تعداد کل تکرارهای آموزشی را ۲۰۰۰۰ تنظیم کردیم. توقف زودهنگام برای پایان دادن خودکار به آموزش فعال شد.

1-2-2-1-2 افزایش داده‌ها

ما چندین استراتژی افزایش تصادفی داده‌ها را در حین آموزش به کار بردیم، از جمله (۱) برش تکه‌های مربعی در مرکز قاب‌های ورودی با ضریب مقیاس‌گذاری که به‌طور تصادفی بین ۰,۷ تا ۱ انتخاب شده است، و اندازه محصولات را به اندازه $224 \times$ تغییر دادیم. (۲) رزولوشن ورودی؛ (۳) چرخش با زاویه ای که به‌طور تصادفی بین $\theta = 25^\circ$ تا $\theta = 25^\circ$ انتخاب شده است. (۴) انعکاس افقی تصادفی، به عنوان مثال، تصاویر را در جهت چپ به راست با احتمال $p = 0.5$ برگرداند. و (۵) کنتراست را با تیره یا روشن کردن تصادفی با ضریب بین ۰,۵ و ۱,۵ تنظیم کنید.

1-2-2-1-2 معیارهای ارزیابی

با استفاده از نتایج مثبت آزمایش RTPCR به عنوان برچسب‌گذاری حقیقت پایه برای گروه COVID-19 و نتایج تشخیص بیماران CAP و NP، دقت، حساسیت و ویژگی چارچوب طبقه‌بندی ما محاسبه شد. ما همچنین منطقه زیر منحنی مشخصه عملکرد گیرنده (AUC) را برای کمی کردن عملکرد طبقه‌بندی خود انجام دادیم.

فصل 3. نتایج و ارزیابی مدل‌های پیشنهادی

1-3 مقدمه

قطعه بندی ریه

را به صورت تصادفی به ۴۰ آموزش، ۱۰ اعتبار و ۱۰ مجموعه TCIA به منظور ارزیابی شبکه تقسیم‌بندی ریه، ۶۰ داده داده آزمایشی مستقل تقسیم کردیم. نتایج مطالعه فرسایشی روش های مختلف پیش پردازش و پس پردازش با استفاده از امتیازات دایس در شکل ۳ نشان داده شده است

B. تشخیص عفونت

(۱) نقشه برداری فعال سازی کلاس در نتیجه یادگیری چند مقیاسی، شکل ۴ نمونه هایی از نقشه های فعال سازی کلاس (COVID-۱۹ CAM) را نشان می دهد که در سطوح مختلف ویژگی، یعنی Conv ۳، Conv ۴ و Conv ۵ به دست آمده اند. دوربین های مدار بسته توزیع فضایی احتمال طبقه بندی را نشان می دهند که در آن مناطق داغ نشان می دهند که مناطق آلوده کجا هستند. هر چه نواحی گرمتر باشند احتمال آلوده شدن آنها بیشتر است. نکته قابل توجه در دوربین های چند مقیاسی، مدل پیشنهادی ما یاد می گیرد که توزیع ضایعات را با مقیاس های مختلف ثبت کند: به عنوان مثال، ضایعات بزرگ مانند ضایعات تکه ای، مانند علامت سنگفرش دیوانه و تحکیم. و همچنین ضایعات کوچک ندول مانند، مانند کدورت شیشه ای (GGO) و ضخیم شدن عروق برونش. اگرچه دوربین های مدار بسته می توانند محل قرارگیری نواحی بیمار را نشان دهند، اما هنوز برای شناسایی و تخمین دقیق وسعت ضایعات بسیار درشت هستند. از سوی دیگر، نقشه های برجسته نشان داده شده در شکل ۵، می توانند اطلاعات سطح پیکسلی را ارائه دهند که وسعت دقیق ضایعات را مشخص می کند و بنابراین می تواند محلی سازی دقیق ضایعات را استنتاج کند. به طور قابل توجهی از نقشه های برجسته، لایه سطح میانی، یعنی Conv ۳ می تواند تشخیص ضایعات کوچک (بیشتر GGO) را بیاموزد، به ویژه آنهایی که به صورت محیطی و زیر پلور توزیع شده اند. با این حال، Conv ۳ قادر به گرفتن ضایعات لکه مانند بزرگتر نیست، و این ممکن است به دلیل میدان پذیرش محدود در لایه میانی باشد. برعکس، لایه های سطح بالاتر، به عنوان مثال Conv ۴ و Conv ۵، دارای ظرفیت

پذیرش کافی برای تشخیص ضایعات منتشر و تکه‌ای مانند علامت سنگفرش دیوانه و تحکیم هستند که اغلب به صورت مرکزی و پری برونش توزیع می‌شوند. با این حال، 4Conv و 5Conv تمایل دارند میزان ضایعات کوچک را بیش از حد تخمین بزنند. ویژگی‌های چند مقیاسی یکدیگر را تکمیل می‌کنند و منجر به محلی‌سازی و تخمین دقیق‌تر وسعت ضایعات می‌شوند، همانطور که از نقشه‌های برجستگی مفصل نشان داده شده است.

3-1-1 رده بندی خاص

شکل ۶ نمونه‌هایی از برجستگی مفصلی خاص را نشان می‌دهد که توسط گرادیان‌های یکپارچه محاسبه شده است. ورودی‌های اصلی را در سمت چپ و برجستگی روکش شده را در سمت راست نشان می‌دهد. دوربین‌های مداربسته نشان داده شده در شکل ۴ فقط توزیع فضایی عفونت را نشان می‌دهند. با این حال، نمی‌توان از آن برای محلی‌سازی دقیق ضایعات استفاده کرد. از سوی دیگر، نقشه‌های برجسته می‌توانند اطلاعاتی در سطح پیکسل ارائه دهند که وسعت دقیق ضایعات را مشخص می‌کند، بنابراین محلی‌سازی دقیق ضایعات را فراهم می‌کند. نقشه‌های برجستگی همچنین می‌تواند برای تشخیص مفید باشد که درصد عفونت در نواحی ریه را می‌توان به طور خودکار تخمین زد. این نقشه‌های برجسته، پیکسل‌هایی را برجسته می‌کنند که به افزایش امتیازهای دسته‌بندی‌های خاص کمک می‌کنند: هر چه پیکسل‌ها روشن‌تر باشند، سهم مهم‌تر است. به طور شهودی، می‌توان این را به این صورت تفسیر کرد که هر چه پیکسل‌ها روشن‌تر باشند، ویژگی‌های حیاتی‌تر شبکه برای تصمیم‌گیری (پیش‌بینی) بیشتر می‌شود. قابل ذکر است که در شکل ۴ و شکل ۶، نه تنها یک تغییر کنتراست بین طبقاتی (به دلیل جمع‌آوری داده‌ها از چند موسسه) بلکه یک تغییر کنتراست درون کلاسی نیز وجود دارد، به خصوص در گروه COVID-19. در آزمایش‌هایمان متوجه شدیم که تطبیق هیستوگرام می‌تواند ضایعات را سرکوب کند، به‌ویژه در تصاویر COVID-19. به عنوان مثال، GGO ناپدید می‌شود یا کمتر آشکار می‌شود. علاوه بر این، این منجر به عملکرد ضعیف تشخیص می‌شود. بنابراین، به جای اعمال مستقیم تطبیق هیستوگرام، ما از تنظیم کنتراست تصادفی در حین پرواز برای تقویت داده‌ها در زمان آموزش استفاده کردیم. این بسیار مؤثر است، همانطور که در شکل ۶ نشان داده شده است، مدل پیشنهادی ما یاد می‌گیرد که نسبت به کنتراست تصویر ثابت باشد و ضایعات را دقیقاً ثبت کند. به طور خاص، در شکل ۸، تصاویر نمونه معمولی را به‌طور تصادفی انتخاب کردیم تا تغییرات کنتراست تصویر در موارد COVID-19 را نشان دهیم و نقشه‌های برجسته به‌دست‌آمده از مدل‌های آموزش دیده با و بدون افزایش کنتراست را مقایسه کردیم (CA در مقابل NCA). ما دریافتیم که بدون افزایش کنتراست، نقشه‌های برجستگی معمولاً پر سر و صدا و در محلی‌سازی ضعیف هستند، زیرا تشخیص اشتباه اغلب در مواردی مانند موارد جزئی از عفونت یا مناطق

بدون عفونت مشاهده می‌شود. در حالی که، با افزایش کنتراست، مدل‌های آموخته شده نقشه‌های برجسته‌تری را تولید می‌کنند و محلی‌سازی مناطق آلوده در برابر تغییرات کنتراست قوی‌تر و دقیق‌تر است. همانطور که مشاهده می‌شود (محصور شده توسط جعبه سبز)، مدل ما با تقویت کنتراست قادر است تمام مناطق بیمار را گرفته و وسعت آنها را دقیقاً برجسته کند، صرف نظر از موارد منفرد یا چندگانه عفونت. علاوه بر این، با توجه به برجسته بودن COVID-19 و CAP، متوجه شدیم که ضایعات CAP در مقایسه با موارد COVID-19 که اغلب مناطق آلوده متعددی دارند و ضایعات گسترده و پراکنده هستند، عموماً کوچکتر و محدودتر هستند. همچنین باید توجه داشت که ضایعات COVID-19 و CAP دارای ویژگی‌های رادیوگرافی مشابهی مانند GGO و ادغام فضای هوایی هستند. علاوه بر این، GGOs اغلب در مناطق ساب پلورال و همچنین در موارد CAP ظاهر می‌شود. جالب توجه است، از نقشه برجسته برای موارد NP، ما دریافتیم که شبکه شریان‌های ریوی را به عنوان ویژگی برجسته می‌گیرد. در نهایت، شکل ۷ جعبه‌های مرزی استخراج شده از نقشه‌های برجسته COVID-19 و CAP را نشان می‌دهد (مرتبط با مثال‌های شکل ۶). ما دریافتیم که نتایج با یافته‌های اولیه ما مطابقت دارد که موارد CAP مناطق آلوده کمتری دارند و اغلب یک مورد عفونت وجود دارد، در مقابل، موارد COVID-19 اغلب مناطق آلوده بیشتری دارند (چند موارد عفونت) و COVID-19 ضایعه از نظر وسعت بسیار متفاوت است. به طور کلی، مناطق آلوده به CAP در مقایسه با مناطق کووید-۱۹ کوچکتر هستند.


3-1-2 عملکرد طبقه بندی

عملکرد طبقه بندی عملکرد مدل پیشنهادی ما برای هر کار خاص با اعتبارسنجی متقاطع ۵ برابری ارزیابی شد. ما از پنج معیار ارزیابی استفاده می‌کنیم که عبارتند از دقت (ACC) دقت (PRC)، حساسیت (SEN)، ویژگی (SPE) و ناحیه زیر منحنی (ROC (AUC). ما میانگین نتایج اعتبار متقابل ۵ برابری را در هر متریک با فاصله اطمینان ۹۵٪ گزارش می‌کنیم. ما همچنین روش پیشنهادی خود را با پیاده‌سازی مجدد شبکه Navigator-Teacher-Scrutinizer (NTS-NET) مقایسه کردیم [۳۷]. همانطور که قبلاً در تنظیمات آزمایشی توضیح داده شد، اساساً ما دو گروه کار داریم: وظایف طبقه‌بندی سه‌طرفه (که با * نشان داده می‌شوند) و وظایف طبقه‌بندی باینری (نشان داده شده با ۰)، و دو پیکربندی یادگیری: یادگیری تک‌مقیاس (نشان داده شده با †). که یک طبقه‌بندی کمکی را به یک سطح ویژگی خاص اختصاص می‌دهد، و یادگیری چند مقیاسی (که با ‡ نشان داده می‌شود) که نمرات پیش‌بینی چند سطحی را جمع‌آوری می‌کند و سپس با یک طبقه‌بندی

مشترک آموزش داده می‌شود. تمام وظایف باینری ذکر شده با یادگیری چند مقیاسی آموزش داده شدند. از نظر طبقه‌بندی سه‌طرفه، متوجه شدیم که یادگیری چند مقیاسی با طبقه‌بندی‌کننده مشترک عملکرد کلی بالاتری نسبت به هر یک از تکالیف یادگیری تک‌مقیاسی دارد. شایان ذکر است که در میان تکالیف یادگیری تک مقیاس، طبقه‌بندی با ویژگی‌های 4Conv و 5Conv عملکرد بسیار مشابهی را در هر متریک به دست می‌آورد که به طور قابل توجهی بهتر از طبقه‌بندی با ویژگی‌های سطح متوسط، یعنی ویژگی‌های 3Conv است. یک توضیح ممکن است

ویژگی‌های سطح متوسط در مقایسه با ویژگی‌های سطح بالاتر، یعنی 4Conv و 5Conv، به اندازه کافی معنایی ندارند. همانطور که می‌دانیم نمایش‌های CNN سطح بالا از نظر معنایی قوی هستند اما در حفظ جزئیات فضایی ضعیف هستند، در حالی که نمایش‌های CNN سطح پایین به خوبی ویژگی‌های محلی را حفظ می‌کنند اما اطلاعات معنایی ندارند. علاوه بر این، قابل توجه است که، به طور کلی، وظایف طبقه‌بندی باینری عملکرد بسیار بهتری نسبت به طبقه‌بندی سه‌طرفه دارند، به‌ویژه در وظایفی مانند 19NP/COVID و NP/CAP. مشاهده می‌شود که مدل پیشنهادی ما در تشخیص موارد COVID-19 از موارد NP به‌طور منطقی خوب است همانطور که نتایج نشان می‌دهد، نشان می‌دهد که میانگین $ACC = 96.2\%$ ، $PRC = 97.3\%$ ، $SEN = 94.5\%$ ، $SPE = 95.3\%$ را به دست می‌آورد. و AUC به ترتیب 0.97 می‌توان این را توضیح داد زیرا طبقه‌بندی باینری پیچیده‌تر است و همچنین عدم قطعیت کمتری نسبت به طبقه‌بندی سه‌طرفه وجود دارد. همچنین ممکن است به این دلیل باشد که ویژگی‌های تصویر COVID-19 و CAP در مقایسه با موارد NP ذاتاً تبعیض‌آمیز هستند. به عنوان مثال، همانطور که موارد COVID-19 قبلاً نشان داده شد، اغلب ترکیبی از الگوهای مختلف بیماری و مناطق بزرگ عفونت در اسکن‌ها وجود دارد. آخرین اما نه کم‌اهمیت، ما متوجه شدیم که عملکرد طبقه‌بندی COVID-19/CAP کمترین برتری را در بین تمام وظایف طبقه‌بندی باینری دارد. یکی از دلایل احتمالی این است که COVID-19 ویژگی‌های رادیوگرافی مشابهی با CAP دارد، مانند GGO و یکپارچه‌سازی فضای هوایی و ظرفیت شبکه ممکن است برای یادگیری بازنمایی‌های خاص بیماری کافی نباشد. با این وجود، نتایج به‌دست‌آمده با استفاده از روش پیشنهادی ما بهتر از نتایج به‌دست‌آمده توسط NTS-NET بود. ما همچنین عملکرد کلی، یعنی طبقه‌بندی‌کننده مشترک را به کلاس‌ها تقسیم می‌کنیم، و معیارهای طبقه‌بندی برای هر کلاس گزارش می‌شوند... ما متوجه شدیم که مدل‌هایی که بدون افزایش کنتراست آموخته‌اند، مغرضانه هستند که عملکرد طبقه‌بندی برای COVID-19 به طور قابل توجهی بهتر از دو کلاس دیگر است. این ممکن است به این دلیل باشد که مدل‌ها یاد می‌گیرند که کلاس‌ها را بر اساس سبک تصویر (کنتراست) به جای محتوا (الگوهای معمولی یا بیماری) تشخیص دهند و کلاس COVID-19 در

داده‌های ما متمایزترین سبک کتتراست (تنوع زیاد در روشنایی) را در بین هر سه دارد. کلاس ها.. علاوه بر این، کلاس‌های «COVID-۱۹» و «NP» عملکرد قابل مقایسه‌ای را در هر معیار نشان می‌دهند و کلاس «NP» حساسیت بالاتری (۹۱,۳٪) نسبت به COVID-۱۹ (۸۷,۶٪) دارد. و CAP (۸۳,۰٪). علاوه بر این، ما دریافتیم که به طور کلی، «COVID» با میانگین AUC ۰,۹۲۳ در مقایسه با «CAP» (۰,۸۶۴) و «NP» (۰,۹۰۱) بهترین عملکرد و متمایزترین کلاس است. . همچنین می‌توان اشاره کرد که نتایج کلی برای کلاس «CAP» نسبتاً پایین‌تر از نتایج «NP» و «COVID-۱۹» است. این می‌تواند با یافته ما در طبقه بندی COVID-19/CAP که به دلیل ظاهر مشابه، کلاس «CAP» به اشتباه به عنوان «COVID-۱۹» طبقه بندی می‌شود، مرتبط باشد. همچنین، یکی دیگر از دلایل احتمالی این است که شبکه می‌توانست با «صدای NP» محدود یاد گرفته باشد و حواسش پرت شود، و ممکن است تعداد کسری از برش‌های غیر آلوده بین نمونه‌های آموزشی CAP وجود داشته باشد. این به این دلیل است که ما از تمام برش‌های موجود از هر موضوع نمونه برداری کردیم و ممکن است چند برش بدون عفونت باشد.



شکل 1-3: نتایج برجستگی مفاصل دسته‌بندی خاص.


3-1-2-1 بحث

بحث‌ها در این کار، ما یک چارچوب جدید یادگیری عمیق با نظارت ضعیف ارائه کرده‌ایم که قادر است ضایعات را در اسکن‌های COVID-19 و CAP CT فقط از روی برجسب سطح تصویر یاد بگیرد و بومی‌سازی کند. متفاوت از سایر آثار، ما از یادگیری بازنمایی در سطوح ویژگی‌های متعدد استفاده می‌کنیم و توضیح داده‌ایم که چه ویژگی‌هایی را می‌توان در هر سطح یاد گرفت. به عنوان مثال، نمایش سطح بالا، یعنی 5Conv ضایعات پیچ‌مانندی را که معمولاً دارای وسعت زیادی هستند را می‌گیرد. با این حال، تمایل به دور انداختن ضایعات موضعی کوچک دارد. این به خوبی با نمایش‌های سطح میانی تکمیل می‌شود (شکل 4)، یعنی 4Conv و 5Conv، که از آنها ضایعات شناسایی شده نیز با یافته

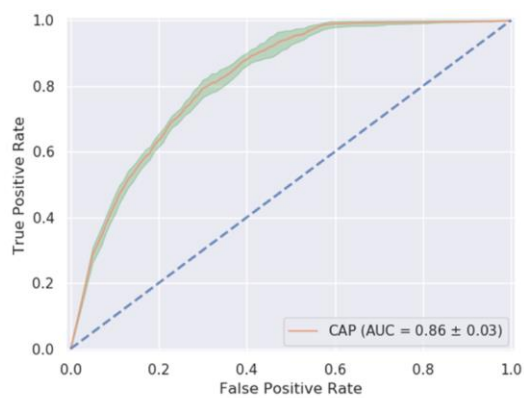
های بالینی ما مطابقت دارد که عفونت ها معمولاً در ریه محیطی (۹۵٪) و عمدتاً در قسمت تحتانی قرار دارند. لوب ریه (۶۵٪)، به ویژه در بخش خلفی (۵۱٪). ما حدس می زنیم که عمدتاً به این دلیل است که برونشیول ها، آلوئول ها، جریان خون غنی و سلول های ایمنی مانند سلول های لنفاوی در محیط اطراف به خوبی توسعه یافته اند. این سلول های ایمنی نقش حیاتی در التهاب ناشی از ویروس داشتند. ما همچنین نشان داده ایم که ترکیب نقشه های برجستگی چند مقیاسی، ایجاد شده توسط گرادیان های یکپارچه، کلید دستیابی به محلی سازی دقیق ضایعات چند نمونه است. علاوه بر این، از منظر بالینی، برجستگی مفصل مفید است که تخمین معقولی از درصد مناطق آلوده ریه ارائه می کند، که عامل مهمی است که پزشکان برای ارزیابی شدت بیمار COVID-۱۹ در نظر می گیرند. علاوه بر این، عملکرد طبقه بندی شبکه پیشنهادی به طور گسترده مورد مطالعه قرار گرفته است که ما نه تنها طبقه بندی سه طرفه بلکه طبقه بندی باینری را با ترکیب هر دو کلاس انجام داده ایم. ما متوجه شدیم که یک محدودیت شبکه پیشنهادی این است که هنگام جدا کردن CAP از COVID-۱۹ به اندازه کافی تبعیض آمیز نیست. ما گمان می کنیم که این به دلیل ظرفیت محدود CNN است که یک راه ساده برای افزایش ظرفیت CNN، افزایش تعداد کانال های ویژگی در هر سطح است. تلاش دیگر در آینده، استفاده از معماری ستون فقرات پیشرفته تر، مانند Resnet و Inception خواهد بود. محدودیت دیگر در این کار این است که ما شبکه ها را بر روی تک تک برش ها (تصاویر) آموزش داده ایم که از تمام نمونه های موجود برای هر موضوع استفاده می کنیم. با این حال، برای افراد CAP یا COVID-۱۹، ممکن است برش های غیر عفونی کسری در بین آنها وجود داشته باشد که می تواند صداهایی را در آموزش ایجاد کند، که با بررسی دقیق توسط پزشکان ما تأیید شده است.

3-2-1-2 نتیجه گیری


نتیجه گیری در این مطالعه، ما یک چارچوب یادگیری عمیق با نظارت ضعیف برای تشخیص و طبقه بندی سریع و کاملاً خودکار عفونت COVID-۱۹ با استفاده از تصاویر CT استخراج شده از چند اسکنر و چند مرکز طراحی کردیم. چارچوب ما می تواند موارد COVID-۱۹ را به طور دقیق از بیماران CAP و NP تشخیص دهد. همچنین می تواند موقعیت دقیق ضایعات یا التهاب های ناشی از کووید ۱۹ را مشخص کند و بنابراین می تواند به طور بالقوه توصیه هایی در مورد شدت بیمار به منظور راهنمایی تریاژ و درمان زیر ارائه دهد. یافته های تجربی نشان داده اند که مدل پیشنهادی به دقت و AUC بالایی برای طبقه بندی، و همچنین تجسم کیفی امیدوارکننده برای تشخیص ضایعه دست می یابد. بر اساس این یافته ها، ما می توانیم یک استقرار در مقیاس بزرگ از چارچوب توسعه یافته را متصور شویم.



(a)



(b)



(c)

شکل 2-3: ویژگی عملکرد گیرنده (ROC) دسته‌های جداگانه برای طبقه‌بندی سه‌طرفه (۵ برابر اعتبار متقاطع). (الف) NP با AUC ۰,۹۰ ± ۰,۰۳ (میانگین انحراف استاندارد). (ب) CAP با AUC ۰,۸۶ ± ۰,۰۳ COVID-19 (c) با AUC ۰,۹۲ ± ۰,۰۲. ناحیه سبز ۹۵٪ CI را نشان می‌دهد-COVID. ۱۹: بیماری کروناویروس ۲۰۱۹، CAP: پنومونی اکتسابی از جامعه، NP: غیر پنومونی، CI: فاصله اطمینان.

**Weakly Supervised Deep Learning for COVID-19 Infection Detection and Classification
From CT Images**

**SHAOPING HU¹, YUAN GAO ^{2,3}, (Member, IEEE), ZHANGMING NIU^{3,4}, YINGHUI
JIANG^{4,5}**

, LAO LI^{4,5}, XIANGLU XIAO^{3,5}, MINHAO WANG^{4,5}, EVANDRO FEI FANG⁶

**, WADE MENPES-SMITH³, JUN XIA⁷, HUI YE⁸, AND GUANG YANG ^{9,10}, (Member,
IEEE) ¹Radiology Department, Hospital of Wuhan Red Cross Society, Wuhan 430015, China**

² Institute of Biomedical Engineering, University of Oxford, Oxford OX3 7DQ, U.K.

³Aladdin Healthcare Technologies Ltd., London EC1Y 0UH, U.K.

⁴Hangzhou Ocean's Smart Boya Company, Ltd., Hangzhou 310016, China

⁵Mind Rank Ltd., Admiralty, Hong Kong

⁶Department of Clinical Molecular Biology, University of Oslo, 0315 Oslo, Norway

⁷Radiology Department, Shenzhen Second People's Hospital, Shenzhen 518035, China

⁸PET-CT Center, Hunan Cancer Hospital, Changsha 410013, China

⁹NHLI, Imperial College London, London SW3 6LY, U.K.

¹⁰Royal Brompton Hospital, London SW3 6NP, U.K.

**Corresponding authors: Hui Ye (yuxin75831@163.com) and Guang Yang
(g.yang@imperial.ac.uk)**